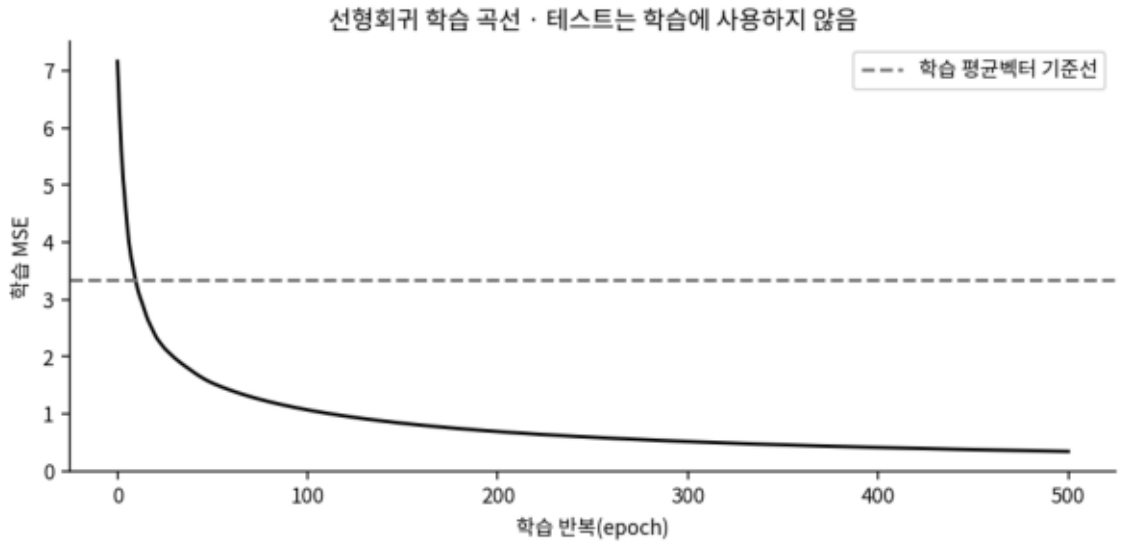
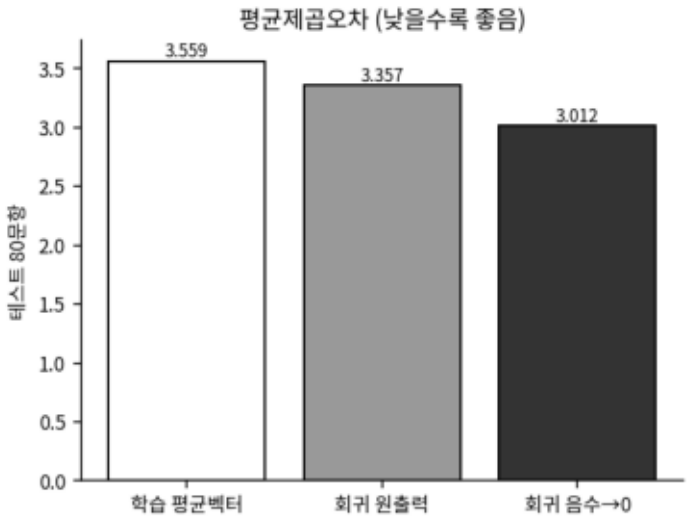
① 회귀 모델 자체 성능

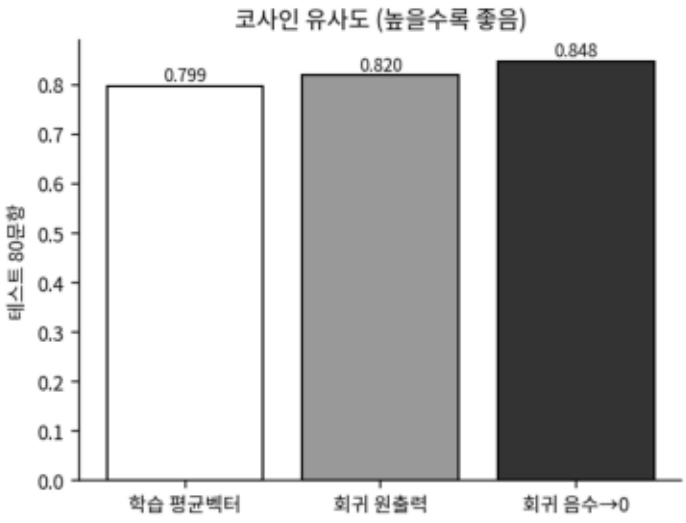
학습 185개 / 테스트 80개 고정 · 문제 346차원 → 해설 431차원

테스트 평가	MSE ↓	MAE ↓	코사인 ↑
회귀 원시 예측	3.3570	0.6229	0.8200
음수를 0으로 조정	3.0125	0.4856	0.8480
학습 평균 벡터 기준선	3.5594	0.4843	0.7986

MSE는 평균 벡터보다 개선됐지만, MAE는 개선되지 않았다.
답변 정답률과 별개로 해설 빈도 벡터의 예측 오차를 측정한 결과다.

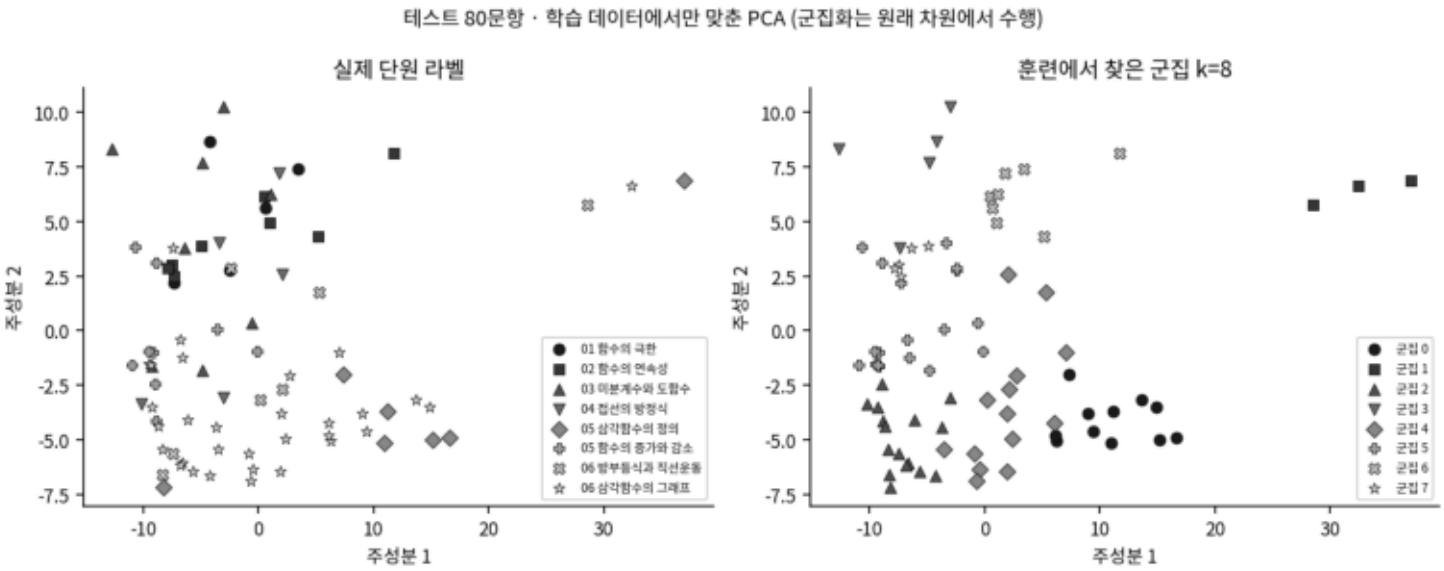






② 군집화와 실제 단원·유형

학습에서만 군집 중심을 계산 · 테스트 80개를 배정하여 평가



군집 수 / 비교	ARI	NMI	테스트 분류 정확도
2 / 과목	0.097	0.104	66.25%
8 / 단원	0.148	0.401	52.50%
70 / 유형	0.167	0.780	36.25%

단원·유형이 일부 반영됐지만 완전히 나뉘지는 않았다.
군집 수가 많으면 NMI가 높아질 수 있어 ARI를 함께 해석해야 한다.
유형별 전체 분포 그림은 02_군집화 폴더에 따로 저장했다.

③ Gemini 정확도와 토큰 비교

같은 테스트 80개 · Gemini 3.1 Flash Lite / minimal / temperature 0

평가	기본 풀이	회귀 상위 20토큰 가이드
원본 정답표 기준	78/80 (97.50%)	77/80 (96.25%)
정답표 오류 보조 보정	79/80 (98.75%)	78/80 (97.50%)
평균 입력 토큰	150.6	395.0
평균 출력 토큰	497.1	462.7
평균 전체 토큰	647.8	857.7
전체 토큰 합	51,820	68,615

이번 실행에서는 정답률 개선 없이 전체 토큰이 32.4% 늘었다.

정답표 충돌: trig_1_010은 원본 ④, 원본 해설 계산은 9/5 = 보기 ②.
원본 기준과 수학 검토 보조 점수를 구분했다. 원본 데이터는 수정하지 않았다.

풀이 적절성 AI 제안: 기본 76적절 / 4부적절,
가이드 71적절 / 7부적절 / 2불확실. 사람의 확정 평가와 구분한다.

80문항에 방식별 1회 생성한 결과다. 성능 차이를 확정할 근거는 부족하다.
대조 응답 77개는 동일 조건을 검증해 재사용했으며 출처를 보존했다.
성공 응답 사용량을 비교했고 추론 토큰은 API 미제공이다.